



Pipeline de Information Retrieval e QA sobre Música


Corpus Musical · BM25 + SBERT · QA Extrativo & Abstrativo

Visão Geral da Pipeline



Tema: artistas, álbuns, géneros, festivais, prémios, eventos e movimentos musicais

Corpus – 110 Documentos



Distribuição intencional: foco em artistas, álbuns e géneros

110 documentos

3 982 chunks

7 tipos

Como foi construído


- ▶ seeds.yaml com 110 entidades
- ▶ Fontes externas: Britannica, Guardian, Billboard...
- ▶ Fallback Wikipedia
- ▶ Auditoria + reparação de docs fracos

Retrieval – BM25 + SBERT + Híbrido

BM25	SBERT	Híbrido
Pesquisa lexical (rank-bm25 + regex) • Compara termos da query com termos dos chunks <u>maior score aos chunks onde esses termos são mais relevantes</u> • Bom para nomes, títulos e datas • Limite: depende do vocabulário	Pesquisa semântica (all-MiniLM-L6-v2) • Chunk → embedding 384 dimensões • Query codificada em runtime • Similaridade cosseno (query e chunks) Capta significado, não só palavras	Combinação ponderada • Normalização min-max • $\alpha=0.6$ (60% SBERT / 40% BM25) • Aplicação fórmula <code>score_final</code> Interface: • Ajustamento do α • Filtro por tipo de doc Melhor resultado global

$$\text{score_final} = (1 - \alpha) \times \text{score_BM25_norm} + \alpha \times \text{score_SBERT_norm}$$

Espaço de Embeddings SBERT (t-SNE)



Agrupamentos semânticos

Alguns artistas próximos dos seus géneros e álbuns,
sem fine-tuning específico

Modelo escolhido

all-MiniLM-L6-v2

22M params · 384D · leve e rápido em CPU

Pré-computação


3 982 embeddings calculados 1x e guardados --> .npy

Apenas a query é codificada em runtime

→ não é preciso recalcular embeddings

Avaliação dos Retrievers

20 queries anotadas manualmente · tipos: artist, album, genre, festival, award, event



Métricas (20 queries)			
Retriever	MRR	P@1	Hit@3
BM25	0.85	0.75	0.90
SBERT	0.93	0.85	1.00
Hybrid	0.95	0.90	1.00

MRR: quanto cedo aparece o 1.º relevante
P@1: 1.º resultado está certo?
Hit@3: há algum relevante no top3?

QA Extrativo – Fine-tuning em SQuAD

Duas abordagens testadas

Configuração	Epochs	Amostras	Exact Match
Abordagem 1	1	87 500	65.24%
Abordagem 2	2	30 000	61.00%
Baseline HF	—	87 500+	71.14%

Conclusão-chave

Mais dados superam mais epochs com subconjunto reduzido.
Abord. 2 mostrou overfitting (eval loss subiu na época 2).
Limitação: sem GPU → difícil igualar baseline HF.

Pipeline extrativa

- Query do utilizador
- Retriever Híbrido → top-k chunks
- Contexto com metadados
- DistilBERT fine-tuned → tenta extrair span de resposta
- $\text{score} = 0.7 \cdot \text{QA} + 0.3 \cdot \text{retrieval}$
- Heurística metadados (casos simples).
Ex: quem lançou um álbum


QA Abstrativo — Pipeline FLAN-T5

Modelo: google/flan-t5-base

- ▶ Seq2seq instruction-tuned (pergunta + contexto → resposta)
- ▶ 250M parâmetros — corre localmente
- ▶ Classificação simples: factual vs. explicativa
- ▶ Fallback de síntese de evidência

Resultados QA (20 queries)

Extractive QA



EM 45%

Abstractive QA



EM 50%

13 generative · 7 metadata

Pipeline abstrativa

1. Query do utilizador
2. Retriever Híbrido → top-k chunks
3. Classificação: factual / explicativa
4. Prompt adequado ao tipo de pergunta
5. FLAN-T5 tenta gerar resposta
6. Fallback: síntese de evidência

QA Abstrativo: Exemplo

Porquê abordagem abstrativa?

Pergunta explicativa

- ▶ Resposta não está num único span
- ▶ Requer evidência de vários chunks
- ▶ Sintetiza impacto cultural, reconhecimento crítico e influência no hip-hop

Exemplo — Abstrativo

Q: Explain why To Pimp a Butterfly is considered important.

A: To Pimp a Butterfly is considered important because it is linked to racial empowerment, a respected space for conscious hip-hop, Kendrick Lamar's status as a major generational artistic voice and the critical and commercial viability of experimental rap.

*answer_method: evidence_synthesis
(fallback de síntese)*

*pipeline selecionou frases relevantes e
construiu uma resposta mais estável a partir
delas.*

Demonstração – Interface Gradio

`python app.py`


`http://127.0.0.1:7860`



Filtro por tipo de doc (album, artist...)



Ajuste de alpha (BM25 ↔ SBERT)



Modo: Extractive / Abstractive / Both



Scores detalhados por chunk

Sequência da Demo

Pergunta	Modo	Filtro	Objetivo
Who released Blonde?	Extractive	album	heurística metadados
What genre is Tame Impala associated with?	Both	artist	comparar respostas
Explain why 2014 Forest Hills Drive is considered important.	Abstractive	album	síntese explicativa
What is trip hop?	Abstractive	genre	definição de género

Conclusões



Híbrido BM25+SBERT mais robusto

$MRR = 0.95 \cdot P@1 = 0.90 \cdot Hit@3 = 1.0$ · Combinar léxico e semântica é mais robusto do que cada abordagem isolada



Fine-tuning extrativo

Mais dados > mais epochs com dataset reduzido · Com recursos limitados, baseline HF é difícil de igualar



Abstrativo melhor em explicativas

Vantagem em perguntas explicativas onde síntese de múltiplos chunks é necessária