



Universidade do Minho

Universidade do Minho

Escola de Engenharia
Departamento de Informática

Scripting e Processamento de Linguagem Natural

Trabalho Prático 2 — Parte 1

Pipeline de Information Retrieval e Question Answering sobre Música

Artistas · Álbuns · Géneros · Festivais · Prémios · Eventos · Movimentos

Mariana Miguel Pinto
pg61534

Ano letivo 2025/2026

Resumo

Este relatório descreve a implementação de uma **pipeline de Information Retrieval (IR) e Question Answering (QA)** sobre um corpus musical. O sistema constrói e processa 110 documentos sobre artistas, álbuns, géneros musicais, festivais, prémios, eventos e movimentos musicais, sobre os quais são construídos um índice lexical BM25 e um índice semântico SBERT, combinados num retriever híbrido ponderado.

Para o módulo de QA foram implementadas duas estratégias: **extrativa**, com fine-tuning de DistilBERT no dataset SQuAD, e **abstrativa**, com prompting ao modelo FLAN-T5-base. O fine-tuning foi realizado em duas abordagens — a primeira com 1 época e o dataset completo (EM = 65,24%) e a segunda com 2 épocas e subconjunto de 30 000 exemplos (EM = 61,00%) — ficando ambas abaixo do baseline de referência (EM = 71,14%) por limitação de recursos computacionais. A solução inclui avaliação quantitativa com 20 queries anotadas manualmente, visualizações e interface web Gradio.

1. Objetivos e Enquadramento

A Parte 1 do TP2 exigia a construção e integração de três componentes principais: um corpus de texto com pelo menos 100 documentos e processamento adequado; um módulo retriever capaz de receber uma query e devolver os documentos mais relevantes por pesquisa lexical, semântica ou híbrida; e um módulo de QA com abordagem extrativa (fine-tuning em SQuAD) e abstrativa (prompting a um modelo generativo).

O tema escolhido foi música, cobrindo artistas, bandas, álbuns, géneros, festivais, prémios, eventos e movimentos musicais. A escolha justifica-se por dois motivos: o domínio combina perguntas factuais simples ("quem lançou este álbum?") e perguntas explicativas mais complexas ("qual a importância cultural deste álbum?"), o que permite testar os dois módulos de QA em condições distintas; e existe informação pública abundante, quer na Wikipedia quer em fontes externas como Britannica, The Guardian, Rolling Stone, Billboard, Rock & Roll Hall of Fame e Pitchfork.

2. Visão Geral da Solução

A arquitetura segue uma pipeline linear com cinco fases: construção e limpeza do corpus, pré-processamento e chunking, indexação (BM25 + SBERT), retrieval híbrido e QA (extrativo + abstrativo). A tabela seguinte mapeia cada componente ao ficheiro correspondente.

Componente	Implementação	Ficheiros principais
Corpus	110 docs com metadados e texto limpo	data/raw/corpus.jsonl, src/build_corpus.py
Auditoria / reparação	Deteção de textos curtos, duplicados e fontes ruidosas	src/audit_corpus.py, src/repair_corpus.py
Pré-processamento	Chunking com overlap sobre texto limpo	src/preprocess.py
Retriever lexical	BM25 sobre tokens normalizados	src/retriever_bm25.py
Retriever semântico	SBERT all-MiniLM-L6-v2, similaridade cosseno	src/retriever_sbert.py
Retriever híbrido	Combinação ponderada BM25 + SBERT (alpha)	src/retriever_hybrid.py
QA extrativo	DistilBERT fine-tuned em SQuAD + heurística de metadados	src/qa_extractive.py, src/train_qa_squad.py
QA abstrativo	FLAN-T5-base com prompting e fallback de evidência	src/qa_abstractive.py
Interface	Aplicação Gradio (http://127.0.0.1:7860)	app.py
Avaliação	MRR, P@1, Hit@3, EM, F1 (20 queries)	src/evaluate.py, src/visualize_eval_metrics.py

Tabela 1 — Componentes da pipeline e ficheiros correspondentes.

3. Corpus

O corpus final contém 110 documentos distribuídos por sete tipos: artist, album, genre, festival, award, event e movement. Cada documento é guardado em JSONL com campos doc_id, title, type, section, source_type, source, url, wikipedia_url e text. A figura 1 mostra a distribuição por tipo.




Figura 1 — Distribuição do corpus por tipo. Os artistas representam a maioria (60 documentos), seguidos de álbuns (25) e gêneros (15).

Tipo de documento	Nº de documentos
artist	60
album	25
genre	15
festival	5
award	3
event	1
movement	1
Total	110

Tabela 2 — Contagem de documentos por tipo.

3.1 Construção do Corpus

O corpus foi construído a partir de um ficheiro **seeds.yaml** com 110 entidades. Para cada entidade, o sistema tentou obter texto de fontes externas como Britannica, The Guardian, Rolling Stone, Billboard, Rock & Roll Hall of Fame, NME e Pitchfork. A Wikipedia foi usada para descobrir links externos relevantes por tipo de entidade e também como fallback quando nenhuma fonte externa produzia texto suficiente.

Quando nenhuma fonte externa produzia texto suficiente (mínimo de 1 800 caracteres), a Wikipedia era usada como fallback (mínimo de 800 caracteres). Esta hierarquia de fontes garantiu textos mais ricos do que uma única fonte homogénea, com publicações especializadas a fornecer análise crítica e contexto cultural, e a Wikipedia a assegurar factos verificáveis para entidades com menor cobertura editorial.

3.2 Auditoria e Reparação

Após a construção inicial, o script **src/audit_corpus.py** analisou cada documento quanto a três critérios: texto demasiado curto (menos de 2 500 caracteres), duplicação de conteúdo (hash MD5) e ausência do título da entidade no texto. Os documentos problemáticos foram substituídos por extratos da Wikipedia via **src/repair_corpus.py**. Os documentos de álbuns foram globalmente migrados para Wikipedia, porque as fontes externas editoriais tendem a incluir mais opiniões e menos factos verificáveis, o que prejudicaria o módulo extrativo.

Durante o desenvolvimento foram usados backups intermédios para preservar versões anteriores do corpus durante as fases de auditoria e reparação. A entrega final inclui apenas o corpus final reparado, de forma a reduzir o tamanho dos artefactos submetidos.

4. Pré-processamento

A pipeline de limpeza em **src/preprocess.py** aplica normalização de espaços e quebras de linha, remoção de boilerplate enciclopédico e eliminação de referências bibliográficas inline do tipo [1]. O chunking usa uma janela deslizante com os seguintes parâmetros:

Parâmetro	Valor
MAX_WORDS (palavras por chunk)	170
OVERLAP_WORDS (sobreposição)	35
MIN_WORDS (mínimo por chunk)	40

Tabela 3 — Parâmetros de chunking.

170 palavras é suficientemente longo para fornecer contexto ao modelo QA (que aceita até 512 tokens com a pergunta incluída) mas suficientemente curto para que os embeddings SBERT, que usam pooling sobre a sequência inteira, não percam resolução semântica por diluição. O overlap de 35 palavras reduz a probabilidade de uma resposta ficar dividida entre dois chunks consecutivos. O resultado são 3 982 chunks, distribuídos da seguinte forma:

Tipo	Nº de chunks
artist	2442
album	769
genre	417
award	160
movement	107
festival	82
event	5
Total	3982

Tabela 4 — Distribuição de chunks por tipo.

5. Retrieval

5.1 BM25 — Retriever Lexical

O **BM25 (Best Match 25)** é uma função de ranking probabilística baseada em TF-IDF com normalização pelo comprimento do documento. A implementação usa a biblioteca **rank-bm25 com tokenização por expressão regular** ([a-zA-Z0-9]+), que normaliza para minúsculas e ignora pontuação. O BM25 é eficaz para queries com termos literais como nomes de álbuns, artistas ou datas, mas falha quando a formulação da query difere do vocabulário presente nos documentos.

5.2 SBERT — Retriever Semântico

O retriever semântico usa o modelo **sentence-transformers/all-MiniLM-L6-v2** (22M parâmetros), especializado em similaridade semântica de frases. Os embeddings dos 3 982 chunks são pré-computados e guardados em **models/sbert_chunk_embeddings.npy** (dimensão 3982×384), normalizados para que o produto interno seja equivalente à similaridade cosseno. Em tempo de inferência, apenas a query é codificada e a comparação é feita por multiplicação matricial contra o índice pré-computado.

O modelo foi escolhido por ser significativamente mais rápido do que alternativas maiores como all-mpnet-base-v2, mantendo boa qualidade semântica para inglês.

5.3 Retriever Híbrido

O retriever híbrido combina os dois retrievers com normalização min-max individual seguida de combinação linear ponderada:

$$\text{score_final} = (1 - \alpha) \times \text{score_BM25_norm} + \alpha \times \text{score_SBERT_norm}$$

O valor por defeito é **alpha = 0,6**, atribuindo mais peso à componente semântica. Em queries com nomes específicos de álbuns ou artistas, o BM25 costuma acertar na primeira posição; em queries formuladas de forma indireta (e.g. "que artista explora o tema da identidade racial?"), o SBERT é necessário para superar a lacuna vocabular. O peso de 0,6 captura este equilíbrio para a maioria das 20 queries de avaliação. O parâmetro alpha é exposto na interface Gradio para ajuste interativo.

5.4 Espaço de Embeddings

A figura 2 mostra a **projeção 2D dos embeddings SBERT dos 110 documentos usando t-SNE com métrica cosseno**. Os agrupamentos semanticamente coerentes visíveis no gráfico — com documentos de género próximos de artistas representativos e álbuns próximos dos respetivos artistas — confirmam que o modelo captura relações relevantes para o domínio musical sem qualquer fine-tuning específico.




Figura 2 — Projeção 2D dos embeddings SBERT (t-SNE, métrica cosseno). Cor e marcador indicam o tipo de documento.

6. Avaliação dos Retrievers

A avaliação foi realizada com 20 queries anotadas manualmente em **data/eval_queries.json**, cobrindo seis dos sete tipos de documento (artist, album, genre, festival, award e event; sem queries para movement, que tem apenas 1 documento no corpus) e incluindo tanto perguntas factuais como explicativas. Para cada query foi definido o conjunto de documentos relevantes e a resposta esperada. As métricas calculadas foram:

- **MRR (Mean Reciprocal Rank)** — média do inverso da posição do primeiro documento relevante; penaliza resultados relevantes em posições baixas.
- **P@1** — proporção de queries em que o primeiro resultado é relevante.
- **Hit@3** — proporção de queries com pelo menos um documento relevante nos três primeiros resultados.




Figura 3 — Comparação dos três retrievers em MRR, P@1 e Hit@3.

Retriever	MRR	P@1	Hit@3
BM25	0,8475	0,7500	0,9000
SBERT	0,9250	0,8500	1,0000
Hybrid	0,9500	0,9000	1,0000

Tabela 5 — Métricas de avaliação dos três retrievers (top-5, 20 queries).

6.1 Análise dos Resultados

Evolução entre estratégias: O SBERT supera o BM25 nos indicadores principais de ranking, com MRR de 0,9250 face a 0,8475 e P@1 de 0,8500 face a 0,7500. O Hybrid, ao combinar os dois, atinge o melhor MRR (0,9500) e P@1 (0,9000), confirmando que a complementaridade léxico-semântica produz um ranking mais robusto do que cada abordagem isolada. O Hit@3 de 1,0000 mostra ainda que, para todas as 20 queries avaliadas, o retriever híbrido colocou pelo menos um documento relevante nos três primeiros resultados.

A métrica **Hit@3** é particularmente adequada neste conjunto de avaliação, porque a maioria das queries tem apenas um documento relevante anotado. Assim, em vez de medir quantos dos três primeiros documentos são relevantes, interessa sobretudo verificar se o sistema consegue colocar pelo menos um documento correto no topo do ranking. Nesse critério, o Hybrid atinge $\text{Hit@3} = 1,0000$.

7. Question Answering Extrativo

7.1 Arquitetura

O módulo extrativo segue a sequência:

query → **retriever híbrido** → **top-k chunks** → **construção do contexto com metadados** → **modelo QA** → **seleção do melhor span**.

Para cada chunk recuperado é construído um contexto que inclui os metadados do documento (título, tipo, fonte, artista quando aplicável) antes do texto, o que ajuda o modelo a responder perguntas cujas respostas estão implícitas no texto mas explícitas nos metadados. O score final de cada resposta candidata combina o score do modelo QA e o score de retrieval do chunk:

$$\text{score_final} = 0,7 \times \text{qa_score} + 0,3 \times \text{retrieval_score}$$

Este ponderamento favorece a qualidade da extração mas ainda penaliza spans provenientes de documentos com baixa relevância de retrieval. Uma camada auxiliar de heurística de metadados, ativada antes do modelo, responde diretamente a perguntas estruturadas simples ("who released...", "what genre is...") com alta precisão e sem invocar a inferência do modelo.

7.2 Fine-tuning em SQuAD — Duas Abordagens

O fine-tuning foi realizado em **duas abordagens distintas**, ambas partindo do modelo base distilbert-base-cased (sem fine-tuning em QA prévio), treinado no dataset SQuAD. O objetivo foi avaliar se mais épocas com menos dados poderiam substituir uma época com o dataset completo.

Configuração	Épocas	Batch	LR	Amostras treino	EM (SQuAD val)
Abordagem 1	1	4	3e-5	87 500 (completo)	65,24%
Abordagem 2	2	8	2e-5	30 000	61,00%
Baseline HuggingFace	—	—	—	87 500+	71,14%

Tabela 6 — Comparação das duas abordagens de fine-tuning e do baseline no split de validação do SQuAD (10 570 exemplos).

7.3 Análise do Processo de Fine-tuning

Abordagem 1 (1 época, 87k exemplos): Obteve EM = 65,24% e F1 = 75,85%. O modelo viu todos os exemplos disponíveis uma vez, o que garante diversidade máxima de padrões de linguagem, ainda que com convergência limitada a uma única passagem.

Abordagem 2 (2 épocas, 30k exemplos): Obteve EM = 61,00% e F1 = 71,47%, um resultado inferior à Abordagem 1 apesar de incluir mais épocas. A explicação está na redução do conjunto de treino para 30 000 exemplos: ao eliminar dois terços dos dados disponíveis, o modelo fica exposto a menos diversidade de padrões linguísticos. O eval loss aumentou ligeiramente entre a época 1 (1,3903) e a época 2 (1,4084), o que sugere que a segunda época introduziu ligeiro overfitting ao subconjunto reduzido.

Por que razão ambas ficam abaixo do baseline: O baseline distilbert-base-cased-distilled-squad não é um modelo genérico — é o resultado do fine-tuning pela HuggingFace com múltiplas épocas, hardware GPU dedicado e otimizações de treino (warm-up scheduling, learning rate decay). Com recursos equivalentes e 3 a 4 épocas sobre o dataset completo, um fine-tuning próprio produziria resultados comparáveis ou superiores ao baseline. O modelo da Abordagem 1 foi mantido em `models/qa_finetuned/` por ter obtido o melhor resultado das duas tentativas.

7.4 Heurística Auxiliar de Metadados

Para um subconjunto de perguntas muito estruturadas — perguntar quem lançou um álbum, qual o género de uma entidade, ou o título de um álbum — a resposta é construída diretamente a partir dos metadados do chunk com melhor ranking, sem invocar o modelo. Esta heurística é ativada antes do modelo QA, evita respostas instáveis para casos triviais, e é apresentada na interface com `answer_method = "metadata"`.

8. Question Answering Abstrativo

8.1 Arquitetura

O **módulo abstrativo** usa **google/flan-t5-base** (250M parâmetros), um modelo seq2seq instruction-tuned que segue instruções em linguagem natural. O modelo foi escolhido por ser suficientemente compacto para correr localmente com latência aceitável para demonstração, por suportar prompts com múltiplos documentos de contexto e por ter sido instruction-tuned de forma a produzir respostas estruturadas quando solicitado.

A pipeline distingue dois tipos de pergunta: **factuais** (quem, quando, qual) e **explicativas** (porquê, como, qual a importância). Para perguntas factuais, o prompt inclui os chunks recuperados com metadados e pede uma resposta direta. Para perguntas explicativas, o sistema seleciona frases de evidência dos chunks por pontuação de relevância e constrói um prompt focado nessa evidência. Quando a resposta gerada é considerada de má qualidade (demasiado curta, circular ou incoerente), um mecanismo de fallback constrói uma resposta a partir dos pontos principais das frases de evidência selecionadas.

8.2 Resultados

Módulo	Exact Match	F1
Extractive QA	45,00%	46,43%
Abstractive QA	50,00%	52,86%

Tabela 7 — Resultados dos módulos de QA nas 20 queries de avaliação.

Nota: a avaliação foi realizada com o modelo extrativo disponível em **models/qa_finetuned/**, correspondente à Abordagem 1. Este modelo foi treinado durante 1 época no dataset completo do SQuAD e obteve EM = 65,24% e F1 = 75,85% no split de validação.

A pipeline abstrativa obteve EM = 50% e F1 = 52,86% nas 20 queries de avaliação, das quais 7 foram respondidas diretamente por heurística de metadados e 13 pelo modelo generativo FLAN-T5, ligeiramente acima do extrativo (EM = 45%, F1 = 46.43%). Esta diferença explica-se pelo tipo de perguntas: para factuais simples, ambos os módulos tendem a acertar; para explicativas, o módulo abstrativo tem a vantagem de poder sintetizar evidência de múltiplos chunks, enquanto o extrativo está restringido a extrair um span contínuo de um único contexto.

9. Interface e Demonstração

A **interface web** foi desenvolvida com **Gradio** e é lançada pelo ficheiro `app.py`, correndo localmente em `http://127.0.0.1:7860`. Esta permite:

- inserir uma pergunta em texto livre;
- seleccionar um filtro por tipo de documento (artist, album, genre, festival, award, event, movement ou sem filtro);
- ajustar o parâmetro alpha entre 0 (só BM25) e 1 (só SBERT);
- escolher o número de documentos a recuperar (top-k de 1 a 10);
- seleccionar o modo de QA: Extrativo, Abstrativo ou ambos.

Os resultados são apresentados em três painéis: **resposta extrativa**, **resposta abstrativa** e **lista dos documentos recuperados com scores detalhados** (score final, BM25 raw, similaridade SBERT). A interface inclui exemplos clicáveis, começando por perguntas seleccionadas para a demonstração e mantendo depois as queries de avaliação como opções adicionais e emite um aviso quando o score do documento topo é baixo ou quando os dois primeiros documentos têm scores muito próximos.

Para lançar a interface:

```
python app.py
```

10. Reprodutibilidade

Todos os artefactos necessários para executar o sistema estão incluídos na entrega: `corpus.jsonl`, `chunks.jsonl`, embeddings SBERT (`.npy`) e modelo QA fine-tuned (`models/qa_finetuned/`). Para verificar o estado após instalação das dependências:

- `pip install -r requirements.txt`
- `python run_project.py check`

Resultado esperado:

```
Corpus documents: 110 | Chunks: 3982 | Embeddings shape: (3982, 384) |  
Fine-tuned QA model: available
```

Comandos principais:

- `python run_project.py search "Who released OK Computer?" --filter-type album`
- `python run_project.py ask "Who released OK Computer?" --mode extractive`
- `python run_project.py ask "Explain why To Pimp a Butterfly is considered important." --mode abstractive`
- `python run_project.py demo-full`

11. Limitações

- O corpus é pequeno e centrado em entidades pré-selecionadas — perguntas sobre artistas ou álbuns fora do corpus não têm resposta.
- O corpus está em inglês; perguntas em português terão desempenho inferior, pois o tokenizer BM25 e o modelo SBERT foram otimizados para inglês.
- O FLAN-T5-base é relativamente pequeno e pode gerar respostas incompletas para perguntas complexas. Um modelo maior produziria respostas abstrativas de melhor qualidade.
- O fine-tuning extrativo ficou abaixo do baseline por limitação de recursos computacionais (ausência de GPU dedicada e número reduzido de épocas). Com 3 a 4 épocas em GPU, o resultado seria comparável ao baseline da HuggingFace.
- A Abordagem 2 de fine-tuning (2 épocas, 30k exemplos) produziu resultados piores do que a Abordagem 1 (1 época, 87k exemplos), revelando que mais dados de treino superam mais épocas quando o subconjunto é reduzido.
- A avaliação usa apenas 20 queries, o que limita a significância estatística — os valores de EM e F1 devem ser interpretados como estimativas.
- A heurística de metadados cobre apenas três padrões de pergunta fixos, sem generalização para outros tipos de perguntas estruturadas.

12. Conclusão

A implementação cumpre todos os requisitos da Parte 1: corpus com 110 documentos, retriever lexical (BM25), semântico (SBERT) e híbrido, QA extrativo com fine-tuning em SQuAD e QA abstrativo com prompting a FLAN-T5-base. De forma a melhorar o projeto, foram ainda adicionados scripts de auditoria e reparação do corpus, avaliação quantitativa com três métricas de retrieval e duas de QA, visualizações do espaço de embeddings e da distribuição do corpus, e interface Gradio.

A principal conclusão técnica ao nível do retrieval é que o **sistema híbrido BM25 + SBERT é a escolha mais robusta** para este domínio: $MRR = 0,95$ e $Hit@3 = 1,0$ confirmam que a combinação de léxico e semântica supera cada abordagem individualmente. Por esse motivo, a avaliação final privilegia MRR , $P@1$ e $Hit@3$, métricas mais adequadas a um conjunto de queries em que a maioria tem apenas um documento relevante anotado.

Para o fine-tuning extrativo, a experiência com duas abordagens revelou uma conclusão importante: mais dados de treino superam mais épocas quando o subconjunto é reduzido. A Abordagem 1 (1 época, 87k exemplos, $EM = 65,24\%$) superou a Abordagem 2 (2 épocas, 30k exemplos, $EM = 61,00\%$), tendo esta última evidenciado ligeiro overfitting ao subconjunto reduzido. Ambas ficaram abaixo do baseline HuggingFace, o que é esperado dado o menor número de épocas e ausência de GPU.

Por fim, o **módulo abstrativo superou o extrativo** na avaliação ($EM = 50\%$ vs. 45%), especialmente em perguntas explicativas onde a síntese de múltiplos chunks é necessária e o extrativo fica limitado a um único span contínuo.

Referências

- [1] Robertson, S. e Zaragoza, H. The Probabilistic Relevance Framework: BM25 and Beyond. *Foundations and Trends in Information Retrieval*, 3(4), 333–389, 2009.
- [2] Reimers, N. e Gurevych, I. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *EMNLP*, 2019.
- [3] Rajpurkar, P., Zhang, J., Lopyrev, K. e Liang, P. SQuAD: 100,000+ Questions for Machine Comprehension of Text. *EMNLP*, 2016.
- [4] Raffel, C. et al. Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer (T5). *JMLR*, 2020.
- [5] Chung, H. W. et al. Scaling Instruction-Finetuned Language Models (FLAN-T5). *arXiv*, 2022.
- [6] Lewis, P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *NeurIPS*, 2020.